

Projet Machine Learning / Maths pour l'apprentissage

Adult Dataset : de l'expérimentation à la professionnalisation

Matthieu PELINGRE

Master 2 SDD

11 avril 2026

Contexte : un défi personnel

L'objectif : Prédire si un individu gagne $> 50\,000\ \$$ par an à partir de données censitaires.

Contexte : un défi personnel

L'objectif : Prédire si un individu gagne $> 50\,000$ \$ par an à partir de données censitaires.

Pourquoi ce dataset ?

Contexte : un défi personnel

L'objectif : Prédire si un individu gagne $> 50\,000\ \$$ par an à partir de données censitaires.

Pourquoi ce dataset ? → confrontation directe avec mon "Moi" d'il y a quelques années :

Contexte : un défi personnel

L'objectif : Prédire si un individu gagne $> 50\ 000\ \$$ par an à partir de données censitaires.

Pourquoi ce dataset ? → confrontation directe avec mon "Moi" d'il y a quelques années :

- **À l'époque** : Découverte des librairies Scikit-Learn et XGBoost. Approche naïve, *Data Leakage* et déséquilibre ignoré, peu de sélection des variables, pas d'optimisation.

Contexte : un défi personnel

L'objectif : Prédire si un individu gagne $> 50\,000\ \$$ par an à partir de données censitaires.

Pourquoi ce dataset ? → confrontation directe avec mon "Moi" d'il y a quelques années :

- **À l'époque** : Découverte des librairies Scikit-Learn et XGBoost. Approche naïve, *Data Leakage* et déséquilibre ignoré, peu de sélection des variables, pas d'optimisation.
- **Aujourd'hui** : Démarche plus rigoureuse, création d'un **Pipeline** robuste, lutte contre le déséquilibre des classes et assurer l'explicabilité.

Contexte : un défi personnel

L'objectif : Prédire si un individu gagne $> 50\,000$ \$ par an à partir de données censitaires.

Pourquoi ce dataset ? → confrontation directe avec mon "Moi" d'il y a quelques années :

- **À l'époque** : Découverte des librairies Scikit-Learn et XGBoost. Approche naïve, *Data Leakage* et déséquilibre ignoré, peu de sélection des variables, pas d'optimisation.
- **Aujourd'hui** : Démarche plus rigoureuse, création d'un **Pipeline** robuste, lutte contre le déséquilibre des classes et assurer l'explicabilité.

Problématique

Classe minoritaire à **24,2 %**.

Objectif : maximiser le **F1-Score (macro)** pour garantir un équilibre Précision/Rappel.


Analyse Exploratoire des Données (EDA)

Que révèlent les données ?

Analyse Exploratoire des Données (EDA)

Que révèlent les données ?

- Les hauts revenus sont corrélés à l'**âge** (maturité professionnelle), au **niveau d'éducation** et à des **gains financiers atypiques** (**capital-gain**).




(a) Distributions par classe de revenu.


Analyse Exploratoire des Données (EDA)

Que révèlent les données ?

- Les hauts revenus sont corrélés à l'**âge** (maturité professionnelle), au **niveau d'éducation** et à des **gains financiers atypiques** (**capital-gain**).
- Le **statut marital** (*Married-civ-spouse*) est le discriminant catégoriel absolu (idem pour **relationship** → redondance).



(a) Distributions par classe de revenu.



(b) Taux de >50K par modalité.

Sélection des caractéristiques (Feature Selection)

Élaguer pour réduire le bruit

À mes débuts, j'avais conservé presque toutes les variables. L'analyse statistique a changé la donne :

Sélection des caractéristiques (Feature Selection)

Élaguer pour réduire le bruit

À mes débuts, j'avais conservé presque toutes les variables. L'analyse statistique a changé la donne :

- **Confirmation statistiques** : Calcul du V de Cramér et de l'Information Mutuelle (MI).

Sélection des caractéristiques (Feature Selection)

Élaguer pour réduire le bruit

À mes débuts, j'avais conservé presque toutes les variables. L'analyse statistique a changé la donne :

- **Confirmation statistiques** : Calcul du V de Cramér et de l'Information Mutuelle (MI).
- **Gestion de la redondance** : **relationship** écartée au profit de **sex** et **marital-status**.



(a) V de Cramér

Sélection des caractéristiques (Feature Selection)


Élaguer pour réduire le bruit

À mes débuts, j'avais conservé presque toutes les variables. L'analyse statistique a changé la donne :

- **Confirmation statistiques** : Calcul du V de Cramér et de l'Information Mutuelle (MI).
- **Gestion de la redondance** : **relationship** écartée au profit de **sex** et **marital-status**.
- **Suppression du bruit** : **race** et **native-subregion** exclues car pouvoir prédictif quasi nul.



(a) V de Cramér



(b) Information Mutuelle (MI).

Préparation des données : évolution de la méthode

Dans les deux cas : suppression de `fnlwgt` (poids stat de pondération) et de `education`, redondante avec `education-num` plus intéressante (encodage selon échelle ordinale).

Préparation des données : évolution de la méthode

Dans les deux cas : suppression de `fnlwgt` (poids stat de pondération) et de `education`, redondante avec `education-num` plus intéressante (encodage selon échelle ordinale).

Les erreurs formatrices (2021) :

La robustesse (2026) :

Préparation des données : évolution de la méthode

Dans les deux cas : suppression de `fnlwgt` (poids stat de pondération) et de `education`, redondante avec `education-num` plus intéressante (encodage selon échelle ordinale).

Les erreurs formatrices (2021) :

- Split aléatoire sans seed (non reproductibles).

La robustesse (2026) :

- Split fixé (`random_state=42`).

Préparation des données : évolution de la méthode

Dans les deux cas : suppression de `fnlwgt` (poids stat de pondération) et de `education`, redondante avec `education-num` plus intéressante (encodage selon échelle ordinale).

Les erreurs formatrices (2021) :

- Split aléatoire sans seed (non reproductibles).
- `pd.get_dummies` appliqué *avant* séparation
→ **Data Leakage**.

La robustesse (2026) :

- Split fixé (`random_state=42`).
- **Encapsulation** dans des `Pipeline` Scikit-Learn (zéro fuite), facilité d'usage.

Préparation des données : évolution de la méthode

Dans les deux cas : suppression de `fnlwgt` (poids stat de pondération) et de `education`, redondante avec `education-num` plus intéressante (encodage selon échelle ordinale).

Les erreurs formatrices (2021) :

- Split aléatoire sans seed (non reproductibles).
- `pd.get_dummies` appliqué *avant* séparation
→ **Data Leakage**.
- **Valeurs manquantes** : Ignorées silencieusement (supprimées de fait lors de l'encodage naïf).

La robustesse (2026) :

- Split fixé (`random_state=42`).
- **Encapsulation** dans des `Pipeline` Scikit-Learn (zéro fuite), facilité d'usage.
- **Traitement ciblé des NaN** :

Préparation des données : évolution de la méthode

Dans les deux cas : suppression de `fnlwgt` (poids stat de pondération) et de `education`, redondante avec `education-num` plus intéressante (encodage selon échelle ordinale).

Les erreurs formatrices (2021) :

- Split aléatoire sans seed (non reproductibles).
- `pd.get_dummies` appliqué *avant* séparation
→ **Data Leakage**.
- **Valeurs manquantes** : Ignorées silencieusement (supprimées de fait lors de l'encodage naïf).

La robustesse (2026) :

- Split fixé (`random_state=42`).
- **Encapsulation** dans des `Pipeline` Scikit-Learn (zéro fuite), facilité d'usage.
- **Traitement ciblé des NaN** :
→ *MCAR* : Lignes exclues.

Préparation des données : évolution de la méthode

Dans les deux cas : suppression de `fnlwgt` (poids stat de pondération) et de `education`, redondante avec `education-num` plus intéressante (encodage selon échelle ordinale).

Les erreurs formatrices (2021) :

- Split aléatoire sans seed (non reproductibles).
- `pd.get_dummies` appliqué *avant* séparation
→ **Data Leakage**.
- **Valeurs manquantes** : Ignorées silencieusement (supprimées de fait lors de l'encodage naïf).

La robustesse (2026) :

- Split fixé (`random_state=42`).
- **Encapsulation** dans des `Pipeline` Scikit-Learn (zéro fuite), facilité d'usage.
- **Traitement ciblé des NaN** :
 - *MCAR* : Lignes exclues.
 - *MNAR* : Remplacées par la modalité *Unknown* (vectrice d'information).

Interfaçage différent en 2021

À l'époque, j'avais utilisé l'API standard (plus optimisée sur GPU) et fait uniquement une **3-fold CV**. Maintenant, puissance de calcul moins problématique, utilisation de l'API Scikit-Learn avec l'objet **XGBClassifier**.

Interfaçage différent en 2021

À l'époque, j'avais utilisé l'API standard (plus optimisée sur GPU) et fait uniquement une **3-fold CV**. Maintenant, puissance de calcul moins problématique, utilisation de l'API Scikit-Learn avec l'objet **XGBClassifier**.

Les modèles testés : Random Forest (parallèle) et XGBoost (séquentiel), modèles ensemblistes très performants sur données tabulaires.

Interfaçage différent en 2021

À l'époque, j'avais utilisé l'API standard (plus optimisée sur GPU) et fait uniquement une **3-fold CV**. Maintenant, puissance de calcul moins problématique, utilisation de l'API Scikit-Learn avec l'objet **XGBClassifier**.

Les modèles testés : Random Forest (parallèle) et XGBoost (séquentiel), modèles ensemblistes très performants sur données tabulaires.

Stratégie d'optimisation (RandomizedSearchCV) :

- Maximisation du F1-Score (macro).

Interfaçage différent en 2021

À l'époque, j'avais utilisé l'API standard (plus optimisée sur GPU) et fait uniquement une **3-fold CV**. Maintenant, puissance de calcul moins problématique, utilisation de l'API Scikit-Learn avec l'objet `XGBClassifier`.

Les modèles testés : Random Forest (parallèle) et XGBoost (séquentiel), modèles ensemblistes très performants sur données tabulaires.

Stratégie d'optimisation (`RandomizedSearchCV`) :

- Maximisation du F1-Score (macro).
- **Surprise sur le déséquilibre :** L'algorithme a rejeté les poids de compensation (`scale_pos_weight`, `class_weight`).

Interfaçage différent en 2021

À l'époque, j'avais utilisé l'API standard (plus optimisée sur GPU) et fait uniquement une **3-fold CV**. Maintenant, puissance de calcul moins problématique, utilisation de l'API Scikit-Learn avec l'objet `XGBClassifier`.

Les modèles testés : Random Forest (parallèle) et XGBoost (séquentiel), modèles ensemblistes très performants sur données tabulaires.

Stratégie d'optimisation (`RandomizedSearchCV`) :

- Maximisation du F1-Score (macro).
- **Surprise sur le déséquilibre** : L'algorithme a rejeté les poids de compensation (`scale_pos_weight`, `class_weight`).
- **Adaptation structurelle** : XGBoost a compensé la rareté en favorisant de nombreux arbres trapus (faible `max_depth`) avec un apprentissage lent (`learning_rate = 0.04`). Random Forest lui a utilisé des arbres profonds (`max_depth=20`) mais élagués (`min_samples_leaf=4`).

Résultats finaux (1/2) : bagging vs boosting

Modèle	Acc	P	R	F1-macro	AUC-ROC
DummyClassifier	0.753	0.376	0.500	0.429	0.500
Random Forest	0.862	0.833	0.775	0.798	0.920
XGBoost	0.871	0.843	0.794	0.814	0.932

Résultats finaux (1/2) : bagging vs boosting

Modèle	Acc	P	R	F1-macro	AUC-ROC
DummyClassifier	0.753	0.376	0.500	0.429	0.500
Random Forest	0.862	0.833	0.775	0.798	0.920
XGBoost	0.871	0.843	0.794	0.814	0.932

Méthodologie efficace :

Résultats finaux (1/2) : bagging vs boosting

Modèle	Acc	P	R	F1-macro	AUC-ROC
DummyClassifier	0.753	0.376	0.500	0.429	0.500
Random Forest	0.862	0.833	0.775	0.798	0.920
XGBoost	0.871	0.843	0.794	0.814	0.932

Méthodologie efficace :

- Random Forest surpasse largement sa **baseline** ($Acc_{max} = 0.858$ et $P_{max} = 0.811$).

Résultats finaux (1/2) : bagging vs boosting

Modèle	Acc	P	R	F1-macro	AUC-ROC
DummyClassifier	0.753	0.376	0.500	0.429	0.500
Random Forest	0.862	0.833	0.775	0.798	0.920
XGBoost	0.871	0.843	0.794	0.814	0.932

Méthodologie efficace :

- Random Forest surpasse largement sa **baseline** ($Acc_{max} = 0.858$ et $P_{max} = 0.811$).
- **XGBoost** devance Random Forest.

Résultats finaux (1/2) : bagging vs boosting

Modèle	Acc	P	R	F1-macro	AUC-ROC
DummyClassifier	0.753	0.376	0.500	0.429	0.500
Random Forest	0.862	0.833	0.775	0.798	0.920
XGBoost	0.871	0.843	0.794	0.814	0.932

Méthodologie efficace :

- Random Forest surpasse largement sa **baseline** ($Acc_{max} = 0.858$ et $P_{max} = 0.811$).
- **XGBoost** devance Random Forest.
- **XGBoost** dépasse de peu la Précision sa **baseline** ($Acc_{max} = 0.877$ et $P_{max} = 0.842$).

Résultats finaux (1/2) : bagging vs boosting

Modèle	Acc	P	R	F1-macro	AUC-ROC
DummyClassifier	0.753	0.376	0.500	0.429	0.500
Random Forest	0.862	0.833	0.775	0.798	0.920
XGBoost	0.871	0.843	0.794	0.814	0.932

Méthodologie efficace :

- Random Forest surpasse largement sa **baseline** ($Acc_{max} = 0.858$ et $P_{max} = 0.811$).
- **XGBoost** devance Random Forest.
- **XGBoost** dépasse de peu la Précision sa **baseline** ($Acc_{max} = 0.877$ et $P_{max} = 0.842$).
- Capacité de discrimination validée par AUC-ROC.

Résultats finaux (2/2) : le saut qualitatif

Modèle XGBoost	Acc	P	R	F1-Score
<i>DummyClassifier</i>	0.753	0.376	0.500	0.429
Première approche (2021)	0.869	0.784	0.609	0.686
Version M2 SDD (2026)	0.871	0.843	0.794	0.814

Résultats finaux (2/2) : le saut qualitatif

Modèle XGBoost	Acc	P	R	F1-Score
<i>DummyClassifier</i>	0.753	0.376	0.500	0.429
Première approche (2021)	0.869	0.784	0.609	0.686
Version M2 SDD (2026)	0.871	0.843	0.794	0.814

Résultats finaux (2/2) : le saut qualitatif

Modèle XGBoost	Acc	P	R	F1-Score
<i>DummyClassifier</i>	0.753	0.376	0.500	0.429
Première approche (2021)	0.869	0.784	0.609	0.686
Version M2 SDD (2026)	0.871	0.843	0.794	0.814

Pourquoi des gens utilisent encore l'Accuracy ?

Résultats finaux (2/2) : le saut qualitatif

Modèle XGBoost	Acc	P	R	F1-Score
<i>DummyClassifier</i>	0.753	0.376	0.500	0.429
Première approche (2021)	0.869	0.784	0.609	0.686
Version M2 SDD (2026)	0.871	0.843	0.794	0.814

Pourquoi des gens utilisent encore l'Accuracy ?

Exactitude (Accuracy) quasi identique (+0.2 %), mais l'approche "*moderne*" a permis de bondir de **+18.5 points sur le Rappel**.

Résultats finaux (2/2) : le saut qualitatif

Modèle XGBoost	Acc	P	R	F1-Score
<i>DummyClassifier</i>	0.753	0.376	0.500	0.429
Première approche (2021)	0.869	0.784	0.609	0.686
Version M2 SDD (2026)	0.871	0.843	0.794	0.814

Pourquoi des gens utilisent encore l'Accuracy ?

Exactitude (Accuracy) quasi identique (+0.2 %), mais l'approche "*moderne*" a permis de bondir de **+18.5 points sur le Rappel**.

Le modèle ne rate plus la classe minoritaire !


Interprétabilité globale : que comprend le modèle ?

Variables prédictives dominantes (Feature Importance XGBoost) :

Interprétabilité globale : que comprend le modèle ?

Variables prédictives dominantes (Feature Importance XGBoost) :

- **45 % de la décision** repose sur le statut marital.




(a) Importance dans la prédiction (Gain).

Interprétabilité globale : que comprend le modèle ?

Variables prédictives dominantes (Feature Importance XGBoost) :

- **45 % de la décision** repose sur le statut marital.
- Les investissements financiers (**capital-gain**) sont dans le Top 3 (intuitions de l'EDA).




(a) Importance dans la prédiction (Gain).


Interprétabilité globale : que comprend le modèle ?

Variables prédictives dominantes (Feature Importance XGBoost) :

- **45 % de la décision** repose sur le statut marital.
- Les investissements financiers (**capital-gain**) sont dans le Top 3 (intuitions de l'EDA).



(a) Importance dans la prédiction (Gain).



(b) Variables les plus utilisées (Weight).

Déploiement et interprétabilité locale (SHAP)

Le **Pipeline** final est sauvegardé via **joblib** pour simuler une inférence en production.

Déploiement et interprétabilité locale (SHAP)

Le **Pipeline** final est sauvegardé via **joblib** pour simuler une inférence en production. Pour interpréter les résultats de la boîte noire, intégration des **SHapley Additive exPlanations** (SHAP).

Déploiement et interprétabilité locale (SHAP)

Le **Pipeline** final est sauvegardé via **jolib** pour simuler une inférence en production. Pour interpréter les résultats de la boîte noire, intégration des **SHapley Additive exPlanations** (SHAP).




Figure : Quelles caractéristiques ont joué dans la prédiction pour cet individu et comment ?

Conclusion

Bilan du projet :

Bilan du projet :

- **Processus** : proche du **Cross-Industry Standard Process for Data Mining (CRISP-DM)**.

Bilan du projet :

- **Processus** : proche du **Cross-Industry Standard Process for Data Mining** (CRISP-DM).
- **Technique** : pipeline Scikit-Learn robuste, et des résultats reproductibles.

Bilan du projet :

- **Processus** : proche du **Cross-Industry Standard Process for Data Mining** (CRISP-DM).
- **Technique** : pipeline Scikit-Learn robuste, et des résultats reproductibles.
- **Performance** : optimisation ciblée (F1-score) qui corrige les faiblesses du premier modèle (2021).

Bilan du projet :

- **Processus** : proche du **Cross-Industry Standard Process for Data Mining** (CRISP-DM).
- **Technique** : pipeline Scikit-Learn robuste, et des résultats reproductibles.
- **Performance** : optimisation ciblée (F1-score) qui corrige les faiblesses du premier modèle (2021).
- **Métier** : modèle auditable grâce à SHAP.

Bilan du projet :

- **Processus** : proche du **Cross-Industry Standard Process for Data Mining** (CRISP-DM).
- **Technique** : pipeline Scikit-Learn robuste, et des résultats reproductibles.
- **Performance** : optimisation ciblée (F1-score) qui corrige les faiblesses du premier modèle (2021).
- **Métier** : modèle auditable grâce à SHAP.
- **Perspectives** : tester d'autres modèles (autres ensemblistes, MLP, modèles de fondation tabulaires), interface graphique pour la production.

Merci pour votre attention !